

Shape Function 生成器

方法设计、验证样例与当前实验信号

shape_function-main

2026 年 4 月 15 日

我们在 query-centered patch 上学习一个局部生成器：

$$\mathcal{G}_\theta : (\mathbf{x}_q, \{\mathbf{X}_i\}_{i=1}^k, \beta, \rho_q) \mapsto \{\phi_i(\mathbf{x}_q)\}_{i=1}^k$$

- 输入：局部节点云、查询点、支撑形状参数、几何上下文
- 输出：该局部 patch 上的 shape-function 权值
- 目标：得到快速的无网格 warm start，而不是做全局场预测

结构约束

$$\sum_i \phi_i = 1, \quad \sum_i \phi_i \mathbf{X}_i = \mathbf{x}_q$$

数值意义

Partition of unity 与一阶一致性是最核心的结构约束。

$$(\mathbf{x}_q, \{\mathbf{X}_i\}, \beta, \rho_q) \xrightarrow{\text{feature construction}} \{\mathbf{f}_i\} \xrightarrow{\text{backbone}} \{l_i\} \xrightarrow{\text{B1-B4 head}} \{\phi_i\}$$

Backbone

- 编码局部几何与 patch 内交互
- 从无网格节点集产生原始 logits
- 当前主模型为 kernel-operator

Structure-preserving head

- 提供正性偏置与 locality 控制
- 做 partition-of-unity 归一化
- 通过 reproducing correction 恢复一致性

$$\mathbf{r}_i = \mathbf{X}_i - \mathbf{x}_q, \quad r_{\max} = \max_i \|\mathbf{r}_i\|, \quad \hat{\mathbf{r}}_i = \frac{\mathbf{r}_i}{r_{\max}}$$

$$\mathbf{f}_i = [\hat{\mathbf{r}}_i, \|\hat{\mathbf{r}}_i\|, \beta, \rho_q]$$

- Query-centered normalization 去掉平移歧义
- Scale normalization 提高跨 patch 的可比性
- ρ_q 汇总 patch 密度、各向异性与局部复杂度

Support radius 修正

Backbone 仍使用 $r_{\max}$ 做归一化尺度, 但 head 使用

$$r_{\text{support}} = \alpha r_{\max}, \quad \alpha = 1.05$$

这样最远邻居不再被窗口函数系统性压成 0。

$$\mathbf{h}_i^{(0)} = \text{MLP}_{\text{lift}}(\mathbf{f}_i)$$

$$\mathbf{g}_{ij}^{(\ell)} = \left[\mathbf{h}_i^{(\ell)} - \mathbf{h}_j^{(\ell)}, \hat{\mathbf{r}}_i, \hat{\mathbf{r}}_j, \|\hat{\mathbf{r}}_i - \hat{\mathbf{r}}_j\| \right]$$

$$\alpha_{ij}^{(\ell)} = \text{softplus}\left(\text{MLP}_{\text{mod}}(\mathbf{g}_{ij}^{(\ell)})\right) \cdot w_{\text{Wendland}}(\|\hat{\mathbf{r}}_i - \hat{\mathbf{r}}_j\|)$$

$$\mathbf{h}_i^{(\ell+1)} = \mathbf{h}_i^{(\ell)} + \sum_j \bar{\alpha}_{ij}^{(\ell)} \mathbf{V}^{(\ell)} \mathbf{h}_j^{(\ell)}$$

设计动机

- 对节点集合具备 permutation awareness
- 依赖相对几何，而不是规则网格结构
- 相比 sorted-distance MLP baseline，归纳偏置更合理

Structure-Preserving Head

B1 Softplus

$$\phi_i^{(1)} = \text{softplus}(l_i)$$

B2 Window modulation

$$\phi_i^{(2)} = \phi_i^{(1)} \cdot w\left(\frac{\|\mathbf{r}_i\|}{r_{\text{support}}}\right)$$

B3 Normalization

$$\phi_i^{\text{base}} = \frac{\phi_i^{(2)}}{\sum_j \phi_j^{(2)} + \varepsilon}$$

B4 Reproducing correction

$$\phi_i = \phi_i^{\text{base}} + \phi_i^{\text{base}} \mathbf{p}_i^\top \mathbf{M}^{-1} \left(\mathbf{b} - \sum_j \phi_j^{\text{base}} \mathbf{p}_j \right)$$

各阶段作用

- B1: 稳定的正性偏置
- B2: locality 与紧支撑
- B3: partition of unity
- B4: 一阶一致性

关键点

B4 之后不能再做归一化，否则一致性修正会被破坏。

Patch-level max-ent teacher

$$z_i = w_i \exp(-\mathbf{r}_i^\top \boldsymbol{\lambda}), \quad \phi_i^{\text{ref}}(\mathbf{x}_q) = \frac{z_i}{\sum_j z_j}$$

Gaussian prior:

$$w_i = \exp\left(-\beta \left(\frac{\|\mathbf{r}_i\|}{r_{\max}}\right)^2\right)$$

训练损失

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \lambda_{\text{cons}} \mathcal{L}_{\text{cons}} + \lambda_{\text{neg}} \mathcal{L}_{\text{neg}}$$

$$\mathcal{L}_{\text{cons}} = \left(\sum_i \phi_i - 1\right)^2 + \left\|\sum_i \phi_i \mathbf{X}_i - \mathbf{x}_q\right\|^2$$


解释

- Teacher 提供 reference-guided warm start
- Data term 拟合 max-ent 参考解
- 约束项与负值惩罚项用于稳定训练

主要指标

- relative L2
- PoU residual
- linear residual
- negative fraction
- $\text{cond}(M)$

首轮生产规模结果





Metric	Kernel	MLP
relative L2	0.1201	0.1791
global L_∞	0.1969	0.2540
neg. fraction	0.0464	0.0776
mean cond(M)	646.3	584.5

初步结论



首轮 production run 中, kernel backbone 在主要精度指标上优于 MLP baseline。

对比视图



左: kernel 与 MLP 的整体对比。
右: 一个常规 patch 上的 clean basis contour。


常规样例：基函数视图




代表性常规 patch

- patch type: mildly_perturbed, $\beta = 3.27$
- relative L2: 0.0141, global L_∞ : 0.0026

常规验证样例




样例 A: 常规 mildly perturbed patch
relative L2 = 0.0141, global $L_\infty = 0.0026$



样例 B: 常规 boundary-truncated patch
relative L2 = 0.1186, 整体仍然稳定

为什么要保留这些常规样例

代表性难例



观察到的现象

- clustered / truncated patch 仍是当前最难的工况
- 难例中依然能看到局部误差集中
- 相比逐点误差, 结构性指标要稳定得多

Relative error 可视化

当前展示的 relative-error cloud 使用

$$\frac{|\phi - \phi^{\text{ref}}|}{\max(|\phi^{\text{ref}}|, \varepsilon)}$$

再配合 floor masking 与 clipping, 因此接近 0 的区域不会再在图上爆炸

方法侧

- 继续检查 teacher prior 与 head locality 的一致性
- 做 head ablation, 单独识别 B4 的贡献
- 构建 OOD patch 与 OOD- β 评估

工程侧

- 保持产物与图像入口的精简默认路径
- 继续提升 production run 的 GPU 利用率
- 把论文、PPT 与实验资产连成稳定 workflow

谢谢